

# Problem Set 7:

## Cluster Robust Inference

ECONOMÍA APLICADA



Universidad de  
**San Andrés**

### **Alumnos:**

JUAN DIEGO BARNES

FRANSISCO LEGASPE

RODRIGO MARTIN

DIEGO FASAN

**Profesor:** MARTÍN ROSSI

**Tutores:** GASTÓN GARCÍA ZVALETA

TOMÁS PACHECO

En este problem set utilizamos el caso presnetado en el paper de Angrist y Levy, “*The Effects of High Stakes High School Achievement Awards: Evidence from a Randomized Trial*”, para observar las diferencias que existen al aplicar diferentes estrategias de inferencia.

Estimamos la siguiente regresion:

$$Bargut_{i,g} = \beta Treated_{i,g} + \delta X + u_{i,g}$$

Donde  $Bargut_{i,g}$  es una variable binaria que toma el valor 1 si el individuo  $i$ , perteneciente a cluster  $g$ , cuenta con un *high school matriculation certificate* (*Bagrut*).  $Treated_{i,g}$  es nuestra variable de interés y  $X$  es un vector de controles que incluye las variables `semarab` y `semrel`, además de efectos fijos por grupo.

Implementando diferentes estrategias de inferencia:

1. Robust standard errors
2. Cluster robust standard errors
3. Wild-bootstrap standard errors
4. Approximate Randomization Test (ARTs)

<i>Bagrut Status</i>				
Treated	0.068	0.068	0.068	0.068
Robust Standar error	(0.014)			
	[0.000]			
Cluster robust standard errors		(0.046)		
		[0.173]		
Wild-bootstrap based			(-)	
			[0.212]	
ARTs based				(-)
				[0.519]
Observations	3821	3821	3821	3821

Standard errors in parentheses, p-values in brackets.

Podemos observar que los efectos del tratamiento solo son estadísticamente significativos o distinto de cero cuando se utilizan errores estándar robustos de White, los cuales son robustos a la heterocedasticidad, de modo que solo estamos asumiendo que los errores son independientes, no necesitamos suponer homocedasticidad para que en este caso la inferencia sea correcta.

Ahora si existen algún tipo de dependencia entre los errores la inferencia anterior seria incorrecta. Asumiendo que la dependencia en el termino de error solo se da dentro de cada grupo  $g$  pero no entre grupos, los errores robustos a cluster nos brindan una estrategia robusta de inferencia, pero como ya observamos bajo esta estrategia nuestros coeficientes estimados dejan de ser significativos.

Aunque esta estrategia nos brinda una estimación consistente de los errores estándar, la consistencia depende del número de grupos sobre el que se clusteriza, entonces el estimador es consistente cuando tanto  $g$  y  $n$  tienden a infinito. De modo que *a priori* tenemos que ser cuidadosos con la interpretación de este resultado, ya que en nuestro caso bajo análisis, a pesar de tener más de 3000 observaciones solo contamos con 11 clusters por lo que no podemos estar seguros de que tan buena aproximación de los verdaderos errores estándar nos brinda esta estrategia. Además requiere que haya poca heterogeneidad entre clusters.

Las estrategias de Wild-bootstrap standard errors y Approximate Randomization Test (ARTs) son alternativas para cuando tenemos pocos clusters. Wild-bootstrap consiste en generar múltiples pseudo-muestras y utilizar los estadísticos computados sobre estas, para inferir la distribución del estadístico. Aunque las simulaciones muestran que suele tener buenos resultados en la práctica con pocos clusters, teóricamente sigue requiriendo que el número de clusters se vaya a infinito, y sigue siendo sensible a la heterogeneidad entre clusters.

La estrategia de Approximate Randomization Test (ARTs), requiere que el efecto de la variable de interés pueda ser estimado dentro de cada cluster, eso sería que debería existir grupo de tratamiento y control dentro de cada cluster. Pero esta estrategia no requiere homogeneidad entre clusters y funciona bien cuando el número de clusters es bajo, pero su validez teórica requiere que el número de observaciones dentro de cada cluster tienda a infinito.